금리 변화가 주가 수익률에 미치는 영향 및 예측 모델 분석
(Analysis of the Impact of Interest Rate Changes on Stock Price Returns and Forecasting Models)

학 교	성신여자대학교
전 공	AI
이 름	김수민
연구 기간	2026.2.14~2026.2.23

목 차

Ⅰ. 서론

1. 연구 배경
2. 연구 목표 및 목적

Ⅱ. 데이터 수집 및 전처리

1. 데이터 수집
2. 데이터 정렬 및 병합
3. 파생 변수 생성
4. 월 단위 데이터 변환 및 시차 변수 생성
5. 학습 데이터와 테스트 데이터 분할
6. 의의

Ⅲ. 분석

1. 상관계수
2. Lag 상관관계
3. OLS 회귀
4. 롤링 변동성
5. 코로나 전후 비교
6. 모델 비교: 선형회귀, 랜덤포레스트

Ⅳ. 분석 결과 통합 시각화 대시보드

1. 설명
2. 그래프 구성

Ⅴ. 결론

Ⅵ. 한계점

Ⅶ. 향후 연구 방향

Ⅰ. 서론

1. 연구 배경

우연히 '돈의 심리학' 책에서 주식과 재테크에 관하여 배우면서, 금융시장과 자산 운용에 관심을 갖게 되었다. 재테크는 자산을 증식하는 방법이며, 변화하는 시장 흐름과 경제 지표에 따라 수익률의 결과가 달라진다. 이러한 투자 수익률에 대한 불확실성을 분석하기 위하여 데이터와 수학적, 통계적 분석을 활용한 정량적 투자 모델을 구축하고 싶다는 생각이 들었다. 이에 따라, 연구 주제를 '금리 변화가 주가 수익률에 미치는 영향 및 예측 모델 분석'으로 설정하게 되었다.

금리는 금융시장 전반에 영향을 미치는 핵심 거시경제 변수이며, 특히 주식 수익률과 밀접한 관계를 맺는다고 알려져 있다. 또한 금리 변화는 투자자 행동과 자산 배분 결정에 큰 영향을 미친다. 하지만 주식 수익률에는 매우 다양한 변수가 작용하기 때문에, 주식 수익률에 대한 예측을 금리와의 단순 상관관계만으로 설명하기는 어렵다고 생각했다. 이를 증명하기 위해, 금리 변화와 주가 수익률의 관계를 통계학적, 시계열적, AI 기반 접근으로 분석한다면 과학적인 근거를 갖춘 투자 예측 모델을 만드는데 이바지할 수 있다고 판단했다.

우리나라는 최근 국내 주가가 급격히 상승함에 따라, 많은 개인 투자자가 충분한 정보를 갖추지 않은 채 주식 시장에 뛰어들고 있다. 또한 코로나 이후 주가 변동성이 급증하여, 개인 투자자가 앞으로의 주가 예측을 하는데 어려움이 높아지리라 생각한다. 이러한 상황에서 AI와 통계학적 분석을 활용한 주가 예측 모델은 개인 투자자가 보다 안정적으로 수익을 관리하고 리스크를 줄이는데 이바지할 수 있다고 예상한다.

결론적으로, 본 연구는 주가 수익률과 금리 변화를 수치와 모델을 기반으로 분석하고, 코로나 전후 시장 특성을 비교하며, 예측 모델을 적용함으로써, 재테크 전략의 과학적 접근 가능성을 탐구할 것이다.

2. 연구 목표 및 목적

가. 금리 수준, 금리 변화, S&P 수익률 간 관계를 분석한다.

- 월별 금리 변화와 수익률의 상관관계 및 Lag 효과를 관찰한다.
- 단순 선형 관계(OLS 회귀)를 통해 변수 간 상호작용을 설명한다.

나. 코로나 이전과 이후 금융시장의 특성을 비교한다.

- 코로나 발생 이전과 이후로 구간을 나누어, 수익률과 변동성 추이를 분석한다.
- 롤링 변동성 시계열 그래프를 통해 외부 충격이 모델 예측에 미치는 영향을 평가한다.

다. 학습 방식에 따른 예측 모델의 성능을 비교한다.

- 선형회귀(Linear Regression)모델과 랜덤포레스트(Random Forest)모델의 평균절대오차(MAE) 및 시각화로 예측 모델의 성능을 비교한다.

라. Python을 기반으로 구현하고, Streamlit으로 시각화한다.

- 데이터 전처리, Lag feature 생성, 모델 학습, 예측까지 Python으로 구현한다.
- Plotly 기반 Streamlit 대시보드를 활용하여 본 분석에 쓰인 그래프를 단일 화면에서 통합적으로 시각화한다.

Ⅱ. 데이터 수집 및 전처리

1. 데이터 수집

본 연구에서는 금융시장 수익률과 금리 변화 간의 관계를 분석하기 위해 두 종류의 시계열 데이터를 사용하였다. 첫 번째는 미국 주식 시장 대표 지수인 S&P500을 추종하는 SPY ETF 가격 데이터이며, 두 번째는 미국 기준금리를 나타내는 연방기금금리(Federal Funds Rate) 데이터이다.

SPY 가격 데이터는 Python 라이브러리 yfinance를 이용하여 Yahoo Finance 서버로부터 자동으로 다운로드하였다. 데이터 수집 기간은 2014년 1월 1일부터 2024년 1월 1일까지이며, 수정 종가(adjusted price)가 반영된 종가 데이터를 사용하였다. 다운로드 과정에서 데이터가 비어 있는 경우 예외 처리를 통해 오류를 발생시키도록 하여 데이터 신뢰성을 확보하였다.

금리 데이터는 미국 세인트루이스 연방준비은행(FRED) 데이터베이스에서 CSV 형식으로 직접 불러왔다. 해당 데이터는 날짜(Date)와 금리(Rate) 컬럼으로 구성되어 있으며, 날짜 형식을 datetime 타입으로 변환한 후 인덱스로 설정하였다.

2. 데이터 정렬 및 병합

주식 데이터와 금리 데이터는 서로 다른 빈도를 갖는다. SPY 데이터는 거래일 기준 데이터이며 금리 데이터는 발표 빈도가 불규칙하다. 따라서 분석을 위해 두 데이터를 동일한 시간 단위로 맞추는 전처리 과정이 필요하다.

금리 데이터는 일별 빈도로 리샘플링하고, 결측값은 직전값을 유지하는 전방 채움(forward fill) 방식을 적용하였다. 이는 금리가 발표되지 않은 날짜에도 직전 금리가 유지된다고 가정하기 위함이다.

이후 두 데이터는 날짜 인덱스를 기준으로 inner join 방식으로 병합하였다. 이 방법은 두 데이터 모두 존재하는 날짜만 유지하므로, 분석 대상의 시점 간 불일치 문제를 제거할 수 있다. 병합 후 결측치는 제거하여 분석 데이터의 일관성을 확보하였다.

3. 파생 변수 생성

분석 정확도를 높이기 위해 원본 변수 외에도 금융 시계열 분석에서 널리 사용되는 파생 변수를 생성하였다.

가. 수익률(return)

$$Return_t = \frac{P_t - P_{t-1}}{P_{t-1}}$$

나. 변동성(volatility)

20일 이동 표준편차로 정의하였다.

$$Volatility_t = \sqrt{\frac{1}{20}\sum_{i=0}^{19}(r_{t-i} - \bar{r}_t)^2}$$

다. 금리 변화량(rate_change)

금리 수준 자체보다 시장에 미치는 충격 효과를 측정하기 위해 다음과 같이 계산하였다.

$$RateChange_t = Rate_t - Rate_{t-1}$$

4. 월 단위 데이터 변환 및 시차 변수 생성

단기 노이즈를 제거하고 거시적 관계를 분석하기 위해 일별 데이터를 월별 평균값으로 변환하였다. 월 단위 리샘플링은 "ME" 옵션을 사용하여 월말 기준 평균값을 계산하였다.

이후 금리 변화가 미래 수익률에 미치는 Lag effect를 분석하기 위해 1개월부터 12개월까지 총 12개의 시차 변수(lag feature)를 생성하였다. 각 시차 변수는 다음과 같이 정의된다.

$$Lag_k = RateChange_{t-k}$$

시차 변수 생성 과정에서 발생한 결측치는 제거하여 모델 입력 데이터의 완전성을 유지하였다.

5. 학습 데이터와 테스트 데이터 분할

코로나 팬데믹이 금융시장 구조에 미친 영향을 분석하기 위해 2020년 3월 1일을 기준으로 데이터를 두 구간으로 분리하였다. 학습 데이터는 2020년 3월 이전이고, 테스트 데이터는 2020년 3월 이후이다. 이 분할 기준은 팬데믹이 글로벌 금융시장 변동성 체계를 구조적으로 변화시킨 시기에 기반한다. 학습 데이터는 모델 학습에 사용되며, 테스트 데이터는 예측 성능 평가에 사용된다.

6. 의의

본 전처리 단계는 단순 데이터 정리가 아니라 모델 성능과 해석 가능성을 동시에 향상하기 위한 핵심 단계이다. 특히 데이터 빈도 통일은 분석 안정성 확보를, 파생 변수 생성은 경제적 의미 반영을, 팬데믹 기준 분할은 금융시장 구조 변화를 의미한다. 즉, 본 연구의 데이터 전처리 과정은 분석 가설을 검증하기 위한 구조 설계 단계라고 할 수 있다.

Ⅲ.분석

본 분석은 Python 기반 데이터 분석 환경 analysis.py로 구현하였다. 시계열 금융 데이터 처리, 통계 분석, 머신러닝 모델링 및 시각화를 위해 다양한 전문 라이브러리를 활용하였다.

데이터 처리 및 구조화에는 Pandas와 NumPy를 사용하여 시계열 정렬, 결측값 처리, 파생 변수 생성(lag 변수 등)을 수행하였다.

통계적 관계 분석을 위해 Statsmodels 라이브러리를 활용하여 OLS 회귀분석을 실시하였다. 머신러닝 기반 예측 모델 구현에는 Scikit-learn 패키지를 사용하였고, 선형 예측 모델인 Linear Regression과 비선형 패턴 학습이 가능한 Random Forest 모델을 적용하여 예측 성능을 비교하였다.

시각화는 Matplotlib과 Seaborn을 활용하여 상관관계 히트맵, 시계열 그래프, 모델 비교 그래프 등을 생성함으로써 분석 결과를 직관적으로 해석할 수 있도록 구성하였다.

1. 상관계수(Correlation Coefficient)

가. 분석 목적

금융시장의 수익률과 금리 변수 간의 선형적 관계 존재 여부와 방향성을 파악하기 위함이다. 특히 금리 수준과 금리 변화가 시장 수익률에 미치는 영향을 정량적으로 확인하는 것을 목표로 한다.

나. 상관계수(Correlation Coefficient, r) 개념

두 변수 사이의 선형적 연관성이나 종속적 관계의 강도와 방향을 -1에서 1 사이의 수치로 나타낸 통계적 지표이다.

r 의 값	해석
$r = 1$	완벽한 양의 선형 관계
$0 < r < 1$	양의 상관 관계
$r = 0$	선형 상관 관계 없음 (독립적)
$-1 < r < 0$	음의 상관 관계
$r = -1$	완벽한 음의 선형 관계

다. 변수 정의

- return: S&P500 ETF(SPY)의 일간 단순 수익률
- Rate: 연방기금금리 월별 데이터를 일 단위로 확장한 금리 수준
- rate_change: 전일 대비 금리 변화량 (금리 조정 발생일에만 값 존재)

라. 분석 결과

상관계수

	return	Rate	rate_change
return	1.000000	0.000653	0.001301
Rate	0.000653	1.000000	0.061598
rate_change	0.001301	0.061598	1.000000

그림1: return, Rate, rate_change 상관계수 결과 출력 화면

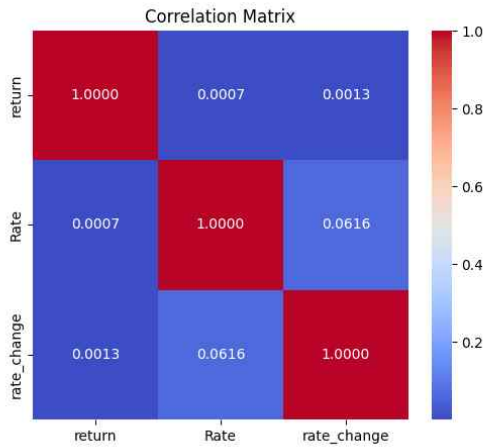

그림2: 상관계수 히트맵

→ 각 상관계수 값을 색깔로 시각화하였다.

마. 결과 해석

- Rate vs rate_change 간 관계 분석

Rate와 rate_change 간 상관계수는 0.061598으로 나타났다. 이는 두 변수 간에 매우 약한 양(+)의 선형 관계가 존재함을 의미한다.

그러나 rate_change 변수는 금리 정책 조정이 발생한 시점에서만 값이 나타나는 특성을 가지므로, 해당 상관관계는 금리 수준과 금리 변화 폭 간 관계라기보다 금리 수준과 금리 조정 이벤트 발생 여부 간 관계를 반영한다고 해석하는 것이 타당하다. 또한, 상관계수가 무시 가능한 정도이기 때문에 통계적·경제적 관점에서 두 변수 간 선형 관계는 사실상 존재하지 않는 수준으로 판단된다. 따라서, 금리 수준 자체가 금리 조정 발생을 설명하는 주요 요인이라고 보기는 어렵다.

- return과 rate_change 간 관계 분석

return과 rate_change 간 상관계수는 0.001301으로 나타났다. 이는 두 변수 간 선형 관계가 거의 존재하지 않는 수준임을 의미한다. 즉, 단기적 관점에서 금리 변동 자체가 주가 수익률과 직접적인 선형 연관성을 갖는다고 보기는 어렵다.

특히 rate_change 변수는 금리 정책 조정이 이루어진 시점에서만 값이 발생하는 특성을 가지므로, 해당 결과는 금리 변동 이벤트가 단기 주가 수익률에 미치는 직접적 영향이 제한적임을 시사한다.

따라서 금리 변동만을 독립변수로 사용하는 단일 예측 모형은 단기 수익률 예측에 있어 실질적인 설명력을 확보하기 어려우며, 이는 금융시장 반응이 단순 금리 변화보다 정책 기대, 시장 심리, 유동성 조건 등 복합적 요인에 의해 결정되기 때문으로 해석된다.

- return과 Rate 간 관계 분석

return과 Rate 간 상관계수는 0.000653으로 나타났다. 이는 두 변수 간 선형 상관관계가 거의 존재하지 않음을 의미한다. 즉, 단기적 관점에서 금리 수준과 주가 수익률 간에는 통계적으로 유의미한 선형 관계가 관측되지 않는다.

따라서 금리 수준 단일 변수만으로 향후 수익률을 설명하거나 예측하는 것은 설명력이 매우 제한적이라고 판단된다. 이는 return과 rate_change 간 관계 분석에서와 같이, 금융시장의 반응은 다양한 영향을 받기 때문이다.

이 결과는 단일 거시 변수 기반 예측 모형의 한계를 시사하며, 보다 높은 설명력을 확보하기 위해서는 Lag 변수, 변동성 지표, 또는 비선형 관계를 반영할 수 있는 다변량 모델이 필요함을 시사한다.

2. Lag 상관관계(Lag Correlation)

가. 분석 목적

Lag 상관관계 분석은 특정 독립변수의 변화가 종속변수에 영향을 미치기까지의 시간 지연(Time Delay) 효과를 평가하는 기법이다.

금리 변화(rate_change)가 주가 수익률(return)에 즉시 반영되지 않고, 몇 개월 이후에 영향을 줄 가능성을 고려하여, 1~12개월의 시차(lag) 변수를 포함한 분석을 수행하였다.

나. 분석 결과

그림3: 1~12개월 Lag 상관계수 그래프

→X축은 금리 변화 이후 주가 수익률에 반영되는 시차(개월)를 나타내며, Y축은 각 시차에서 금리 변화와 수익률 간의 상관계수를 나타낸다.

다. 결과 해석

Lag 1개월까지는 약한 음의 상관 관계가 관측되며, Lag 2~12개월의 상관관계는 거의 0에 가깝다. 즉, 모든 Lag 구간에서 상관계수 절댓값이 0.3 미만으로 나타나, 금리 변화가 단기 및 중기적으로 주가 수익률에 미치는 영향은 통계적으로 매우 약한 수준임을 확인하였다. 이는 단일 금리 지표 기반의 수익률 예측에는 한계가 있으며, 보다 정확한 예측을 위해서는 다변량 모델이 필요함을 시사한다.

3. OLS(Ordinary Least Squares, 일반최소제곱법) 회귀

가. 분석 목적

금리 변화가 주가 수익률에 미치는 영향을 분석하기 위해 다음과 같은 선형회귀 모델을 설정하였다. 이를 통해 금리 변화가 수익률 변동의 설명 변수로서 통계적으로 유의한지 검증하고자 한다.

나. 회귀모형 설정

$return_t = \beta_0 + \beta_1 * rate_change_t + \epsilon_t$

- β_0 :절편(금리 변화가 0일 때 기대 수익률)
- β_1 :금리 변화가 수익률에 미치는 영향 계수
- ϵ_t :오차항

다. 가설 설정

- 귀무가설(H_0): 금리 변화는 수익률에 영향을 주지 않는다. $H_0: \beta_1 = 0$
- 대립가설(H_1): 금리 변화는 수익률에 영향을 미친다. $H_1: \beta_1 \neq 0$

라. 평가 지표 정의

- p-value(유의확률): 독립변수가 종속변수에 미치는 영향이 우연일 확률이다. 즉, 해당 변수가 통계적으로 유의미한지 판단하는 지표이다.

p-value	해석
p-value < 0.05	귀무가설 기각. 독립변수와 종속변수 간의 관계가 통계적으로 유의미하다.
p-value ≥ 0.05	귀무가설 채택. 독립변수와 종속변수 간의 관계가 우연일 가능성이 높아, 통계적으로 유의미하지 않다.

- R-squared(결정계수, R^2): 모델이 실제 데이터(종속변수)의 변동성을 얼마나 잘 설명하는지 나타내는 지표이다. 즉, 모델의 적합도(Goodness of Fit)를 판단한다.

R^2	해석
0	모델이 데이터를 거의 설명하지 못한다.
1	모델이 데이터를 완벽히 설명한다. (과적합 가능성 유의)

- coef(회귀계수): 독립변수가 1단위 증가할 때 종속변수가 평균적으로 얼마나 변하는지를 나타내는 기울기 값이다.

마. 분석 결과

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 return   R-squared:                       0.000
Model:                            OLS   Adj. R-squared:                 -0.000
Method:                 Least Squares   F-statistic:                 0.004223
Date:                Thu, 19 Feb 2026   Prob (F-statistic):              0.948
Time:                        19:29:12   Log-Likelihood:                 7701.9
No. Observations:                2496   AIC:                        -1.540e+04
Df Residuals:                    2494   BIC:                        -1.539e+04
Df Model:                           1
Covariance Type:            nonrobust
===============================================================================
                  coef    std err          t      P>|t|      [0.025      0.975]
-------------------------------------------------------------------------------
const           0.0005      0.000      2.363      0.018    8.91e-05       0.001
rate_change     0.0004      0.006      0.065      0.948      -0.011       0.011
==============================================================================
Omnibus:                      624.090   Durbin-Watson:                   2.243
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            17726.912
Skew:                          -0.550   Prob(JB):                         0.00
Kurtosis:                      16.009   Cond. No.                         25.2
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

그림4: rate_change와 return 간 OLS 회귀 결과 출력 화면

그림5: rate_change와 return 산점도 및 회귀선

→ Actual Return(산점도)은 실제 수익률 관측치를 나타내며, OLS Prediction(회귀선)은 두 변수 간 선형 관계를 추정한 결과이다. 그래프에서 회귀선의 기울기가 거의 0에 가까워 선형 관계가 미약함을 확인할 수 있다.

사. 결과 해석

독립변수인 금리 변화율(rate_change)의 coef는 0.0004로 나타났으며, p-value는 0.948로 유의수준 0.05 기준에서 통계적으로 유의하지 않았다. 이는 금리 변화가 일간 주가 수익률(return)에 선형적으로 유의미한 영향을 미친다고 보기 어렵다는 것을 의미한다.

또한 결정계수 R^2 값이 0.000으로 나타나, 금리 변화 변수만으로는 수익률 변동을 전혀 설명하지 못하는 것으로 확인되었다. 즉, 금리 변화는 단일 설명 변수로서 수익률 변동성의 예측 변수로 활용될 수 없다.

산점도와 회귀선을 함께 고려하면, 관측치들이 회귀선 주변에 집중되지 않고 넓게 분산되어 있으며 회귀선 또한 수평에 가까운 형태를 보인다. 이러한 시각적 결과는 회귀계수 및 결정계수 분석 결과와 일관되게, 두 변수 간 선형 관계가 사실상 존재하지 않음을 시사한다.

한편 상수항(const)의 coef는 0.0005이며 p-value는 0.018로 통계적으로 유의하였다. 이는 금리 변화가 0일 때에도 수익률이 자체적인 평균 움직임을 가진다는 것을 의미하며, 시장 수익률이 금리 변화 외의 다른 요인들에 의해 형성되고 있음을 시사한다.

종합하면, 금리 변화는 단기 주가 수익률을 설명하는 주요 요인으로 보기 어렵고, 금융시장은 다양한 정보 요인의 결합으로 결정되는 복합적 구조를 갖추고 있음을 반영한다. 따라서 더 높은 설명력을 확보하기 위해서는 다변량 모델의 도입이 필요하다.

4. 롤링 변동성(Rolling Volatility)

가. 개념 정의

롤링 변동성은 자산 가격의 변동성이 시간에 따라 어떻게 변화하는지를 나타내는 시계열 기반 위험 지표이다. 이는 설정한 기간 동안 수익률 변동성을 계산하여, 시장 위험의 변화를 파악하는 데 사용된다.

나. 산출 방법

S&P500 일간 수익률의 20일 이동 표준편차를 계산하여 롤링 변동성을 산출하였다. 이 방법은 단기 시장 위험 수준을 시계열적으로 추적할 수 있도록 해준다.

다. 그래프 해석 기준

롤링 변동성 그래프는 시장 위험 수준을 직관적으로 해석할 수 있도록 한다. 변동성이 상승하는 구간은 시장 불확실성과 가격 변동 폭 증가를 의미하며, 이는 위험 수준 상승을 시사한다. 반대로 변동성이 하락하는 구간은 시장이 안정되고 가격 움직임이 완만해지고 있음을 의미한다. 또한 급격한 변동성 피크는 금융위기, 정책 충격, 지정학적 사건 등 외생적 요인에 의해 발생하는 시장 불안정 국면을 나타낸다.

라. 분석 결과

그림6: 롤링 변동성 시계열 그래프

→ 2020년 초에 변동성이 급격히 상승하고, 점차 완화되는 것을 확인할 수 있다.

마. 결과 해석

10년간 롤링 변동성 시계열을 분석한 결과, 2020년 초 코로나 팬데믹 시점에서 변동성이 급격히 상승하는 현상이 관측되었다. 이는 시장이 외생 충격에 대해 단기적으로 매우 민감하게 반응했음을 보여준다. 변동성은 해당 시기에 급등하였으나 이후 비교적 빠르게 정상 수준으로 회귀하였다. 이러한 패턴은 장기적 변동성 군집(volatility clustering)이라기보다 외부 충격으로 발생한 충격 기반 단기 변동성 급등(Shock-driven volatility spike)으로 해석할 수 있다.

또한 앞선 상관관계 분석 및 회귀 분석 결과에서 금리 변화율은 수익률에 통계적으로 유의한 영향을 보이지 않았다. 이를 종합하면, 단기 주가 수익률의 변동성은 금리 요인보다 팬데믹과 같은 외생 충격 변수에 상대적으로 더 민감하게 반응했을 가능성이 있다.

5. 코로나 전후 비교

```
===== 코로나 전후 통계 =====

Before COVID
Return mean: 0.0004407225752050903
Volatility mean: 0.007454425565096242

After COVID
Return mean: 0.000657683361556156
Volatility mean: 0.012052414202705032
```

그림7: 코로나 전후 수익률, 변동성 출력 화면

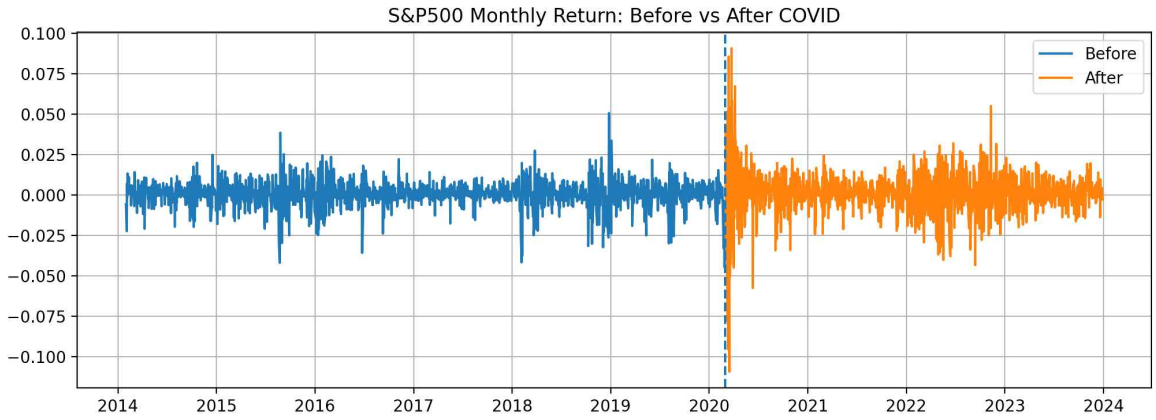

그림8: 코로나 전후 수익률 그래프

→ 코로나 이후 평균 수익률이 이전보다 소폭 상승한 것을 보여준다.

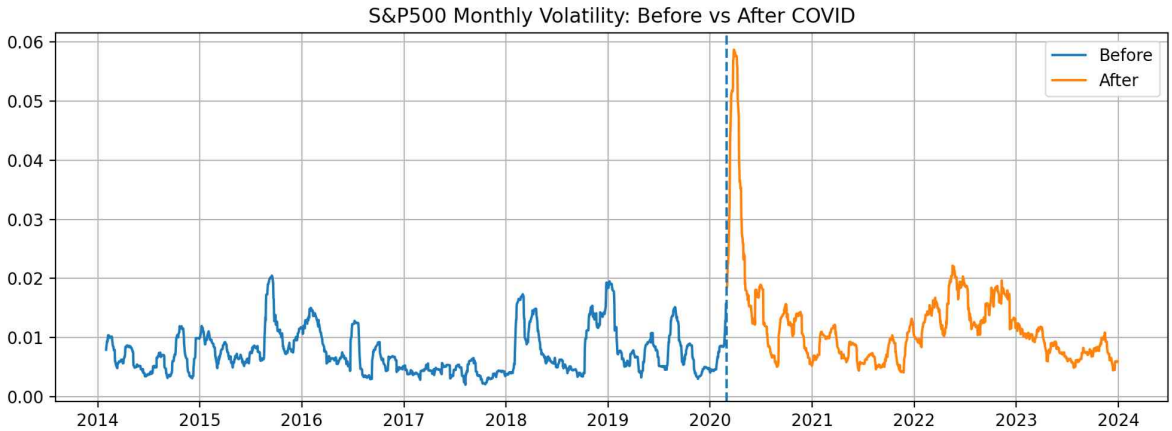

그림9: 코로나 전후 변동성 그래프

→ 2020년 초에 변동성이 급등하고, 점차 완화되는 것을 확인할 수 있다.

가. 수익률 해석

코로나 이전 평균 수익률은 0.0044, 코로나 이후 평균 수익률은 0.0065로 나타났다. 이는 코로나 이후 평균 수익률이 소폭 상승했음을 의미하며, 팬데믹 이후 유동성 공급, 통화 완화 정책, 기술주 중심의 시장 상승 등의 영향이 이러한 구조적 변화를 초래했을 가능성이 있다. 즉, 코로나는 시장을 붕괴시킨 사건이 아니라 수익률 상승 추세를 이끈 사건으로 해석할 수 있다.

나. 변동성 해석

코로나 이전 변동성은 0.00745, 코로나 이후 변동성은 0.01205로 나타났으며, 코로나 이후 변동성이 약 60% 이상 증가하였다. 수익률 상승과 동시에 변동성이 급등한 현상은 단순 금리 요인만으로 설명하기 어렵다. 롤링 변동성 분석에서 확인된 바와 같이, 금리 변화는 단기 변동성 급등을 유발하지 못하며, 시장은 외부 충격에 상대적으로 민감하게 반응하였다. 즉, 하이리스크·하이리턴 환경의 구조로 전환되었다고 평가할 수 있다.

다. 종합 해석

2020년 초 코로나 팬데믹 시점에서, 수익률 상승과 변동성 급등이 동시에 관측되었으며, 이는 단기 S&P500 가격 변동이 금리 변화보다 외부 충격(팬데믹 등)에 더 크게 영향을 받았음을 시사한다. 이러한 분석은 금융시장의 구조적 변화와 위험 수준을 평가하기 위해서는 시계열적 분석과 외생 사건 고려가 필수적임을 나타낸다.

6. 모델 비교: 선형회귀(Linear Regression), 랜덤포레스트(Random Forest)

가. 모델 개요

- 선형회귀(Linear Regression): 독립변수와 종속변수 간의 선형 관계를 예측하는 가장 기본적인 통계 모델이다.
- 랜덤포레스트(Random Forest): 여러 개의 의사결정나무(Decision Tree)를 배깅(Bagging) 방식으로 학습시키고, 그 결과들을 모두 종합하여 예측 정확도를 높이는 머신러닝 알고리즘이다.

나. 분석 결과

```
=== 모델별 평균절대오차(MAE) Before/After COVID ===
                    Before_COVID  After_COVID
Linear Regression       0.001039     0.003230
Random Forest           0.000497     0.002498
```

그림10: 모델별 코로나 전후 평균절대오차(MAE) 출력 화면

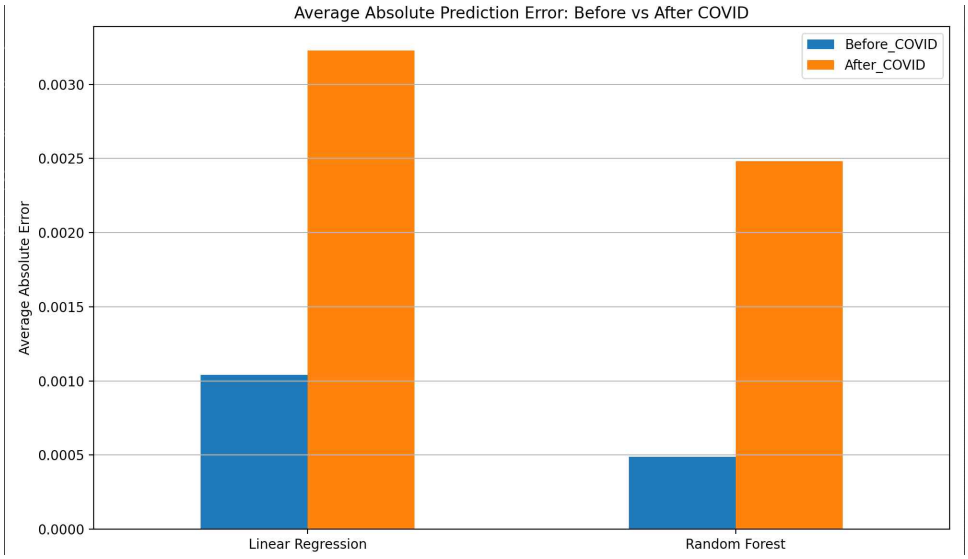

그림11: 모델별 코로나 전후 평균 절대오차(MAE) 막대그래프

→ 두 모델의 평균 절대 오차(MAE)를 코로나 전후로 비교한 그래프로, Random Forest가 Linear Regression보다 예측력이 높음을 보여준다.

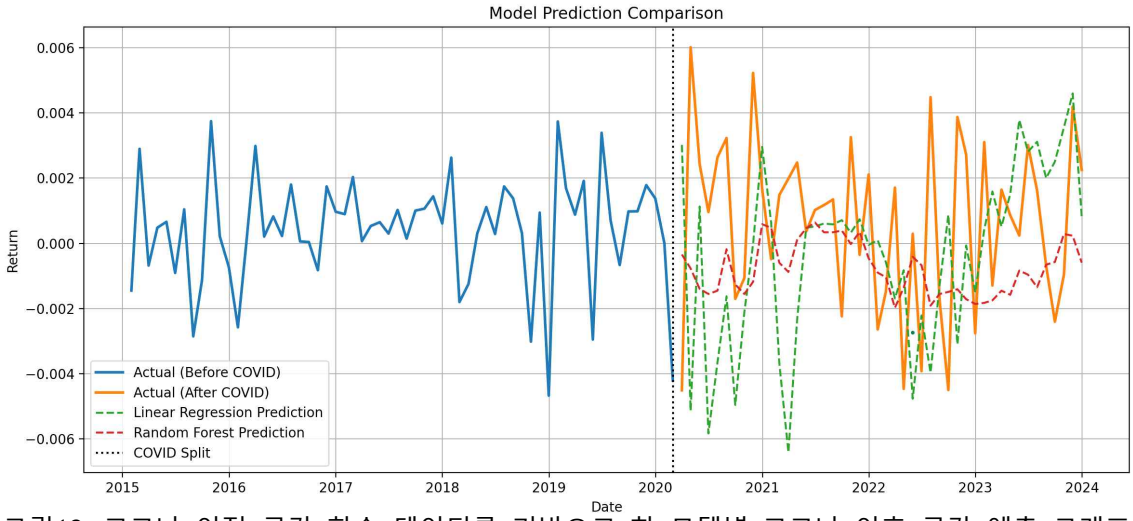

그림12: 코로나 이전 구간 학습 데이터를 기반으로 한 모델별 코로나 이후 구간 예측 그래프
→ Linear Regression은 대부분 평균 수준을 따라가는 경향이 있으나, Random Forest는 변동성을 일부 포착하여 실제 수익률과 더 근접하다.

다. 결과 해석

코로나 이후, 두 모델 모두 평균 절대 오차가 증가하여 S&P500 수익률 예측 난이도가 높아졌음을 확인할 수 있다. 이는 코로나 팬데믹으로 인한 시장 불확실성 증가가 반영된 결과로 해석된다.

또한, 모든 기간 동안 Random Forest 모델이 Linear Regression보다 낮은 MAE를 나타내, 비선형 관계와 변수 간 상호작용을 고려할 수 있는 머신러닝 모델이 단순 선형모델보다 주가 수익률 예측에서 상대적으로 더 우수함을 시사한다.

그림12에서 Linear Regression은 대부분 평균 수준을 따라가는 경향을 보였다. 이는 선형회귀가 금리와 주가 수익률 간 단순 선형 관계만을 반영하기 때문에, 코로나와 같은 외생 충격으로 발생한 급격한 변동성을 충분히 포착하지 못했음을 의미한다. 반면 Random Forest는 데이터 내 비선형 관계와 변수 상호작용을 반영하여 실제 수익률의 변동성을 일부 포착하고, 선형회귀보다 실제 흐름에 근접한 예측을 나타낸다.

종합하면, 금리와 주가 수익률 간에 단순 선형 관계가 존재하지 않으며, 예측 정확도를 높이기 위해서는 비선형 관계와 복합 변수 효과를 반영하는 모델이 필요함을 의미한다.

IV. 분석 결과 통합 시각화 대시보드

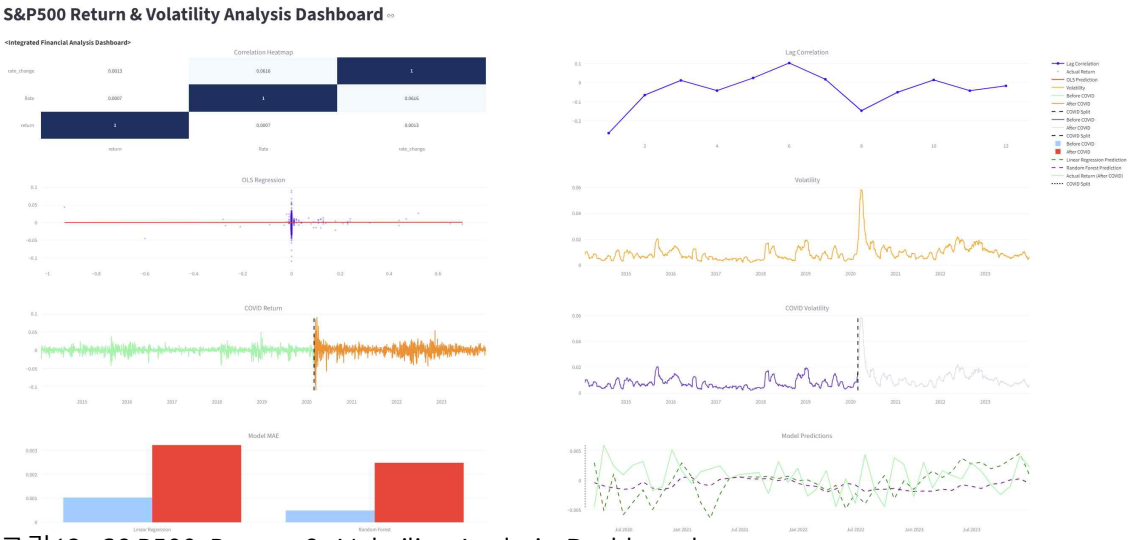

그림13: S&P500 Return & Volatility Analysis Dashboard

1. 설명

본 대시보드는 S&P500 월별 수익률(return)과 변동성(volatility)의 시계열 특성과 금리 수준(Rate) 및 금리 변화(rate_change) 간 관계를 다각도로 분석하기 위해 제작된 Plotly 기반 통합 시각화 도구이다. 단일 화면 내에 상관관계 히트맵, Lag 상관관계 분석, OLS 회귀 분석, 변동성 시계열, 코로나 전·후 수익률 및 변동성 비교 그래프, 예측 모델 성능(MAE) 비교, 실제값 대비 예측값 시각화를 모두 통합하여 제공함으로써 개별 그래프를 분리하여 해석할 때 발생할 수 있는 정보 단절 문제를 최소화하였다.

또한 사용자는 인터랙티브 기능을 통해 특정 시점의 데이터 값을 직접 확인하거나 구간 확대를 수행할 수 있어, 단순 정적 그래프보다 분석 결과에 대한 해석 정확도와 직관성을 동시에 향상할 수 있다. 이를 통해 금리 변화가 시장 수익률과 변동성에 미치는 영향, 코로나 이후 시장 구조 변화, 그리고 예측 모델의 실제 설명력 및 일반화 성능을 종합적으로 평가할 수 있다.

2. 그래프 구성

가. Correlation Heatmap (좌상단)

- S&P500 수익률, 금리(Rate), 금리 변화(rate_change) 간 상관관계를 시각화
- 분석 포인트: 금리 변화와 수익률 간 상관관계 거의 없음

나. Lag Correlation (우상단)

- 과거 1~12개월 금리 변화가 현재 수익률에 미치는 상관관계
- 분석 포인트: 금리 변화가 단기 및 중기적으로 수익률에 미치는 영향은 매우 약한 수준임

다. OLS Regression (2행 좌측)

- 금리 변화(rate_change)가 수익률(return)에 미치는 선형 영향 분석
- 점: Actual Return, 선: OLS prediction
- 분석 포인트: 금리 변화가 수익률에 미치는 영향이 크지 않음

라. Volatility 시계열 (2행 우측)

- 월별 변동성 추이를 시계열로 표현
- 분석 포인트: 2020년 초 변동성 급등

마. COVID Return (3행 좌측)

- 코로나 이전/이후 수익률 비교
- 점선: 코로나 기준일(2020-03-01) 표시
- 분석 포인트: 코로나 이후 수익률 확대

바. COVID Volatility (3행 우측)

- 코로나 이전/이후 변동성 비교
- 점선: 코로나 기준일(2020-03-01) 표시
- 분석 포인트: 2020년 초 코로나 시기 변동성 급등

사. Model MAE (4행 좌측)

- Linear Regression과 Random Forest 모델의 평균절대오차(MAE) 비교
- 분석 포인트: Random Forest 모델이 코로나 전후 모두 Linear Regression보다 MAE가 낮아서 예측 성능이 우수함

아. Model Predictions (4행 우측)

- 코로나 이후 실제 수익률과 모델별 예측 비교
- 초록색 점선 : Linear Regression Prediction, 보라색 점섬: Random Forest Prediction, 실선: Actual Rate(After COVID), 검은색 점선: 코로나 기준일
- 분석 포인트: Random Forest 모델이 실제 수익률 패턴을 비교적 잘 추적함

Ⅴ. 결론

본 연구는 금리 변수와 주식 시장 수익률 간의 관계를 분석하고, 팬데믹 전후 시장 구조 변화가 예측 성능에 미치는 영향을 검증하는 것을 목표로 하였다. 이를 위해 S&P500 ETF 수익률과 연방기금금리를 활용하여 상관관계 분석, 회귀 분석, Lag 상관관계 분석, 그리고 선형회귀와 랜덤포레스트 비교를 시행하였다.

상관계수 분석 결과, 금리 수준, 금리 변화, 시장 수익률 간에는 전반적으로 유의미한 상관계가 관측되지 않았다. 이러한 결과는 금융시장 움직임이 단일 금리 변수보다는 복합 요인의 영향을 받는다는 점을 시사하였다.

또한 Lag 상관관계 분석에서는 금리 변화가 단기 및 중기적으로 주가 수익률에 미치는 영향은 통계적으로 매우 약한 수준임을 확인하였다.

OLS 회귀 분석에서는 금리 변화가 수익률 변동을 일정 부분 설명하지만, 단일 변수 기반 선형모형만으로 시장 움직임을 충분히 설명하기에는 한계가 존재함이 나타났다.

코로나 전후 구분 기준선을 설정하고 데이터를 분석한 결과, 2020년 초 코로나 팬데믹 시점에서 수익률 상승과 변동성 급등이 동시에 관측되었다. 이는 단기 주식 가격 변동이 금리 변화보다 외부 충격(팬데믹 등)에 더 크게 영향을 받았음을 시사하였다.

특히 선형회귀와 랜덤포레스트 모델 비교 결과, Random Forest는 Linear Regression보다 전반적으로 낮은 예측 오차를 보였으며, 비선형 관계를 포착하는 능력이 금융 시계열 예측에 유리함을 시사하였다.

종합적으로, 본 연구는 다음과 같은 시사점을 제시한다. 첫째, 금융시장 분석에서 단일 금리 변수는 시장 수익률을 설명하기 어렵다. 둘째, 시장 구조가 급격히 변화하는 시기에는 과거 데이터 기반 모델의 예측력이 저하될 수 있다. 셋째, 금융 시계열 분석에서는 선형모형과 비선형모형을 함께 고려하는 접근이 필요하다.

Ⅵ. 한계점

본 연구는 금융시장과 금리 간의 관계를 다각적으로 분석하였으나 다음과 같은 한계가 존재한다.

첫째, 설명 변수가 제한적이다. 본 연구는 금리 수준과 금리 변화량을 중심 변수로 설정하였기 때문에 실제 시장 수익률에 영향을 미칠 수 있는 다른 거시경제 변수들(예: 인플레이션, 실업률, 환율, 기업 실적 등) 을 충분히 반영하지 못하였다.

둘째, 구조적 변화 반영의 한계이다. 코로나(2020년 3월 1일)를 기준으로 데이터를 나누어 분석하였으나, 코로나 팬데믹 외의 정책 변화, 지정학적 리스크, 유동성 환경 변화 등 복합적인 체제 변화를 반영하지 못하였다.

셋째, 모델 복잡도의 제약이다. 비교 모델로 선형회귀와 랜덤포레스트만을 사용하였으며, 딥러닝 기반 시계열 모델이나 상태 공간 모형(State-Space Model, SSM)과 같은 고급 예측 기법은 포함하지 않았다. 따라서 대규모 데이터를 통해 포착할 수 있는 비선형성과 장기 의존성을 측정하지 못하였다.

넷째, 변동성 측정 방식이 단순하다. 본 연구에서는 20일 이동 표준편차를 변동성 지표로 사용하였으나, 이는 금융시장 위험을 완전하게 반영하는 지표라고 보기 어렵다. 예를 들어 GARCH 모델과 같은 조건부 변동성 모델을 사용하면 더욱 정확하게 예측할 수 있다.

Ⅶ. 향후 연구 방향

본 연구 결과를 확장하고 예측 성능을 향상하기 위해 추후 다음과 같은 후속 연구를 진행하려고 한다.

첫째, 다요인 거시경제 변수 통합 분석이다. 금리 변수뿐 아니라 물가, 경기지표, 통화량, 신용스프레드 등 다양한 거시경제 요인을 함께 고려한 다변량 모델을 구축하면 시장 수익률 변동의 설명력을 높일 수 있을 것이다.

둘째, 고급 시계열 모델 도입이다. LSTM, Transformer 기반 시계열 모델, 또는 VAR·GARCH 계열 모델을 적용하면 금융시장의 비선형 구조와 시간 의존성을 더욱 효과적으로 포착할 수 있다. 이는 특히 위기 구간에서 예측 성능 개선에 기여할 가능성이 있다.

셋째, 체제 전환 분석이다. 금융시장은 정상 국면과 위기 국면에서 서로 다른 확률 구조를

가지므로, Markov Regime Switching 모형이나 구조적 단절 검정 기법을 활용하면 시장 체제 변화를 정량적으로 분석할 수 있다.

넷째, 정책 효과 분석 확장이다. 이벤트 스터디(event study) 기법을 적용하여 정책 발표 직후 시장 반응을 고빈도 데이터 수준에서 분석할 수 있다. 이는 금리 변화의 즉각적 충격 효과를 정밀하게 측정할 수 있다.

따라서 향후 연구에서는 이러한 확장 방향성을 통합적으로 반영하여, 한국 금융시장 데이터와 뉴스 정보를 실시간으로 분석할 수 있는 AI 기반 금융 분석 시스템을 구축하고자 한다. 다요인 거시경제 변수 통합 모형, 고급 시계열 예측 기법, 체제 전환분석, 정책 발표 및 주요 경제 뉴스 발생 시점의 시장 반응을 고려하는 방법들을 반영할 것이다. 이는 본 연구의 단일 모형 기반 분석의 한계를 보완하고, 금융시장에 대한 예측력과 설명력을 동시에 향상할 수 있다고 예상한다.